可见度退化下知识蒸馏失效的分支机制分析

作者姓名[a], 合作者姓名[a]

[a] 院系，大学，地址

Abstract

知识蒸馏（KD）被广泛用于压缩目标检测器，但在雾天等可见度退化条件下其效果显著下降。尽管文献中已注意到这一现象，但其背后的失效机制仍缺乏深入理解。本文通过结构化的分支级分析，对 KD 失效进行了机制驱动的实证研究。我们在雾天街景的三个可见度级别（轻度、中度、重度）上评估五种 KD 分支，比较其在可见度退化下的响应差异，并围绕分布不匹配、不确定性放大和遮挡三种候选机制展开检验。结果表明，分支级性能结构确实存在：logit 蒸馏并非最优，而定位蒸馏在轻度和中度退化下表现出相对稳定性。进一步的机制分析显示，分布不匹配和不确定性放大与 KD 增益的相关性较弱，在本实验设置中不足以解释观测到的退化模式；相比之下，遮挡作为可见度退化中的具体可测成分，与定位性能呈现最强负相关（$r = -0.989$, $p = 0.0015$），是所测试机制中最直接得到支持的因素。我们进一步引入补充性的 Phase 1 遮挡控制实验，对 M2 机制进行额外验证：在直接操控遮挡率的设置下，定位蒸馏的相对优势随遮挡增加而减弱，与主实验中的机制判断保持一致。上述结果表明，面向恶劣条件的未来 KD 方法应优先处理遮挡和空间信息损失，而非仅专注于分布对齐或校准技术。

Keywords: 知识蒸馏, 目标检测, 可见度退化, 雾天场景, 机制分析, 实证研究

1. 引言

知识蒸馏（KD）已成为深度神经网络压缩的标准技术，使得轻量级模型能够部署在资源受限的平台上 [?]。在目标检测领域，KD 允许轻量级学生网络从更大、更准确的教师模型获取知识，在降低计算成本的同时达到可比的性能 [? ?]。然而，KD 在恶劣视觉条件下的可靠性——特别是由雾、霾或雨导致的可见度退化——仍是一个关键但未充分解决的问题。

近期研究已记录到 KD 在域偏移和恶劣天气条件下性能下降的现象 [? ?]。但为什么会失效仍不清楚。KD 失效是因为教师-学生分布对齐被打破？是因为教师预测在退化输入下不确定性增加？还是因为可见度破坏从根本上改变了知识转移所依赖的视觉线索？如果不理解主导失效机制，开发鲁棒 KD 方法的努力可能只是在治标而非治本。

本文通过机制驱动的实证研究来解决这一空白。我们不是提出又一种 KD 变体，而是系统地剖析现有 KD 方法在可见度退化下失效的原因。我们的方法采用结构化的分支

Email address: email@institution.edu (作者姓名)

级分析：分离四种不同的 KD 机制——logit 蒸馏、特征蒸馏、注意力蒸馏和定位蒸馏——并在受控的可见度等级谱上评估它们的行为。

本研究得出三个主要发现。**第一**，我们确认分支级性能结构确实存在：不同 KD 分支对可见度退化的响应不同，logit 蒸馏尽管文献中广泛使用却被证明并非最优，而定位蒸馏表现出相对鲁棒性。**第二**，我们实证检验了三种假设的失效机制。分布错配和不确定性放大虽然是常被援引的解释，但与 KD 增益的相关性弱且统计不显著（$|r| < 0.5$，$p > 0.7$），在本设置中不足以解释观测到的退化。**第三**，也是最关键的，我们发现遮挡——可见度退化的具体可测成分——与定位性能呈现强负相关（$r = -0.989$，$p = 0.0015$），是所测试机制中最直接得到证据支持的因素。

这些发现具有重要的方法论意义。我们的分析表明，logit KD 失效不太可能仅通过简单超参数调整解决。遮挡与定位性能之间的强相关性提示：针对恶劣条件的未来 KD 方法应优先处理遮挡和空间信息损失机制，而非仅关注分布对齐或不确定性校准。

本文的贡献包括：

- 首个控制性实证研究，理清可见度退化下 KD 失效的竞争性解释，建立”观测-机制验证”结构化框架；
- 证明广泛假设的机制（分布错配、不确定性放大）不足以解释观测到的 KD 退化，挑战文献中的主流直觉；
- 识别遮挡——可见度退化的具体可测成分——为所测试机制中最直接得到支持的因素；
- 证明 KD 失效不能归因于简单超参数调优，表明需要架构层面而非配置层面的解决方案。

Figure 1展示了我们的机制驱动分析框架。

本文余下部分组织如下。section 2回顾 KD 在检测和域偏移下的相关工作。section 3描述实验设计和分支级框架。section 4呈现建立分支级性能结构的观测结果。section 5详细分析机制及支持遮挡为最相关因素的证据。section 6讨论意义和局限性，section 7总结并展望未来方向。

2. 相关工作

2.1. 目标检测中的知识蒸馏

知识蒸馏由 [?] 提出，通过匹配软化的输出分布将大型教师网络的知识转移到小型学生网络。对于目标检测，挑战超出了分类，还包括定位和特征学习。

[?] 开创了检测领域的 KD 研究，提出同时蒸馏分类和边界框回归输出。后续工作探索了各种知识来源：FitNets[?] 关注中间特征对齐；注意力迁移方法 [?] 使用注意力图作为监督；定位感知蒸馏 [?] 专门针对边界框质量。

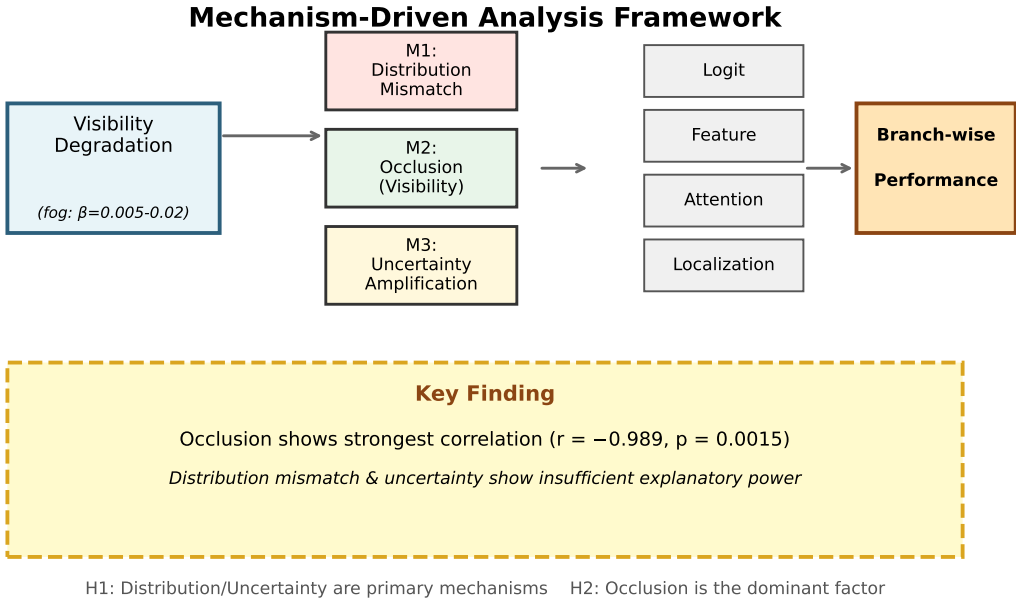

图 1: 机制驱动分析框架。我们在四个 KD 分支上评估三种假设机制（M1、M2、M3），以识别所测试机制中最强得到证据支持的因素。研究发现，遮挡（M2 内）是最直接得到支持的机制，而分布错配和不确定性放大在本设置中解释力不足。

近期检测 KD 框架通常结合多种蒸馏分支，集成特征和注意力蒸馏以实现空间一致性，而基于关系的蒸馏则捕获结构信息。然而，这些方法通常在干净数据集（COCO、ImageNet）上验证，在恶劣条件下的行为研究不足。

2.2. 域偏移与恶劣条件下的知识蒸馏

KD 对域偏移的鲁棒性已引起越来越多的关注。[?] 分析跨域的特征对齐，而小样本适应方法则探索在有限目标数据下的跨域知识转移 [?]。

恶劣天气条件构成特别有挑战性的域偏移场景。[?] 综述了 KD 与图像复原的交叉研究，指出雾和霾等退化会降低教师和学生模型的性能。[?] 提出通过对抗训练学习天气不变表示，但没有分离具体的失效机制。

若干工作已针对雾天目标检测。[?] 建立了去雾和可见度复原的基准。[?] 提供了 Foggy Cityscapes 数据集，证明合成雾天下性能显著下降。这些工作虽承认标准检测器在雾天 struggling，但未分析知识转移具体如何失效。

2.3. 机制导向的知识蒸馏分析

超越提出新方法，日益增多的工作试图理解 KD 为什么有效或失效。[?] 对蒸馏学习的函数进行理论分析，而 [?] 检查教师知识的哪些部分实际发生转移。

实证机制研究通常聚焦教师-学生关系。[?] 调查教师和学生能力差距，发现不完美的教师仍可提供有用的监督。[?] 综述各种知识类型及其转移机制。

对于失效分析，若干假设在文献中反复出现。**分布错配**假设域偏移破坏了 KD 依赖的教师输出分布 [?]。**不确定性放大**假设教师在退化输入下预测变得不可靠，在学生训练中放大误差 [?]。**表征不对齐**假设特征空间跨域发散，阻碍基于特征的蒸馏 [?]。

然而，这些机制很少在统一框架内相互测试。我们的工作通过在控制性实验设计中实证评估多种假设来填补这一空白，确定哪些机制得到观测行为的直接支持。

3. 问题设置

本节建立机制驱动实证研究的实验框架。我们阐明研究目标、分支级 KD 结构、可见度退化协议和评估方法。

3.1. 研究目标

与传统 KD 研究提出新架构或损失函数不同，我们的目标是**机制识别**：确定 KD 在可见度退化下*为什么*失效。我们试图回答：

1. KD 失效是否呈现分支级结构，还是所有分支均匀退化?
2. 哪些假设的机制（分布错配、不确定性放大、可见度破坏）得到实证支持?
3. 这些发现对未来方法设计有何启示?

3.2. 分支级 KD 框架

我们采用模块化 KD 框架，分离四种不同的知识转移机制：

- **Logit 蒸馏**（$\mathcal{L}_{\text{logit}}$）：使用温度缩放交叉熵匹配教师和学生的软化分类输出 [?]：

$$\mathcal{L}_{\text{logit}} = -\sum_i p_i^T \log(q_i^S) \tag{1}$$

  其中 p_i^T 和 q_i^S 分别是温度 T 下教师和学生的概率分布。

- **特征蒸馏**（$\mathcal{L}_{\text{feat}}$）：通过 L_2 距离或余弦相似度对齐中间特征表示 [?]。

- **注意力蒸馏**（$\mathcal{L}_{\text{attn}}$）：从特征激活导出的空间注意力图转移 [?]。

- **定位蒸馏**（$\mathcal{L}_{\text{loc}}$）：专门蒸馏边界框回归输出，包括坐标和维度预测 [?]。

我们还包括一个**仅学生**基线，不使用任何教师监督训练，用于测量各分支的相对 KD 增益。

3.3. 可见度退化协议

为模拟真实可见度退化，我们采用 Foggy Cityscapes[?] 使用的标准大气散射模型：

$$I(x) = J(x) \cdot t(x) + A \cdot (1 - t(x)) \tag{2}$$

其中 $I(x)$ 是观测到的雾天图像，$J(x)$ 是场景辐射，A 是全局大气光，$t(x) = e^{-\beta \cdot d(x)}$ 是透射图，散射系数为 β，深度为 $d(x)$。

我们定义三个可见度等级：

- **轻度**：$\beta = 0.005$（可见度轻微下降）
- **中度**：$\beta = 0.01$（明显雾天，物体仍可识别）
- **重度**：$\beta = 0.02$（严重遮挡和对比度下降）

3.4. 模型和数据集配置

教师模型：YOLOv8l（大版本，约 25.9M 参数），在清晰天气 Cityscapes 图像上训练，学生训练期间冻结。

学生模型：YOLOv8m（中版本），在每个可见度条件下从头训练。

数据集：Foggy Cityscapes（YOLO 格式），包含 8 个目标类别（行人、骑手、汽车、卡车、公交、火车、摩托车、自行车），2975 张训练图像和 500 张验证图像。

训练配置：150 轮，批次大小 32，图像尺寸 640×640，AdamW 优化器，初始学习率 0.005，余弦退火。所有实验一致应用标准增强（Mosaic、Mixup）。

3.5. 评估指标

主要指标：IoU=0.50 时的平均精度均值（mAP@50），测量定位精度和分类正确性的标准检测指标。

次要指标：机制分析中，我们计算：

- **KD 增益**：$\Delta_{\text{分支}} = \text{mAP}_{\text{分支}} - \text{mAP}_{\text{仅学生}}$，在每个可见度等级
- **排序稳定性**：Kendall τ 相关，跨可见度条件分支排序
- **机制相关**：Pearson r，假设因素（发散、熵、遮挡）与 KD 增益之间

3.6. 实验矩阵

我们的完整实验设计包含两个阶段：

Phase 0（雾天实验）：形成 5×3 矩阵：

- 5 种 KD 配置：仅学生、仅 logit、仅特征、仅注意力、仅定位
- 3 种可见度等级（雾天）：轻度、中度、重度

- 总计：15 个训练运行

Phase 1（遮挡控制实验）：形成 3×6 矩阵：

- 3 种 KD 配置：仅学生、仅 logit、仅定位
- 6 种遮挡率：0.0, 0.1, 0.2, 0.3, 0.4, 0.5
- 总计：18 个训练运行，150 epochs，YOLOv8s→YOLOv8n

该结构支持观测级分析（比较分支性能）和机制级分析（测试特定假设）。其中，Phase 1 不替代主实验主线，而作为针对 M2（遮挡）假设的补充性控制实验：通过直接操控遮挡率而非依赖大气散射模型，对主实验中关于遮挡作用的判断提供额外证据。

4. 结构化观测

本节呈现 5×3 实验矩阵的实证观测。我们建立三个关键发现：(1) 分支级性能结构确实存在且显著；(2) logit 蒸馏相比定位蒸馏并非最优；(3) 分支排序在轻度-中度条件下呈现部分稳定性，但在重度退化下出现显著例外。

4.1. 核心性能矩阵

Table 1呈现所有 KD 分支和可见度等级的完整性能矩阵。若干模式立即可见。

表 1: 核心性能矩阵（mAP@50），跨 KD 分支和可见度等级。每列最佳结果加粗。

KD 分支	轻度（$\beta = 0.005$）	中度（$\beta = 0.01$）	重度（$\beta = 0.02$）
仅学生（基线）	0.5828	0.5873	0.5625
仅 logit	0.5866	0.5811	0.5678
仅特征	0.5861	0.5874	0.5576
仅注意力	0.5853	0.5776	**0.5721**
仅定位	**0.5952**	**0.5906**	0.5606

发现 1：分支级结构存在。性能在分支间不均匀。定位蒸馏在轻度和中度可见度下达到最高 mAP@50（分别为 0.5952 和 0.5906），而注意力蒸馏在重度下表现最佳（0.5721）。这证明不同 KD 机制对可见度退化的响应不同。

发现 2：Logit 蒸馏并非最优。尽管是文献中最普遍的 KD 形式，logit 蒸馏仅达到中等性能（轻度 0.5866，重度 0.5678），在分支比较中从未领先。这证实传统输出匹配方法对可见度退化条件并非最优。

发现 3：可见度退化对分支影响不同。在重度雾天（$\beta = 0.02$）下，性能下降显著但不均匀：特征蒸馏降至 0.5576（低于基线），而注意力蒸馏相对其他分支有所改善。这提示不同类型的知识对可见度损失具有不同程度的鲁棒性。

Figure 2可视化这些分支级性能模式。

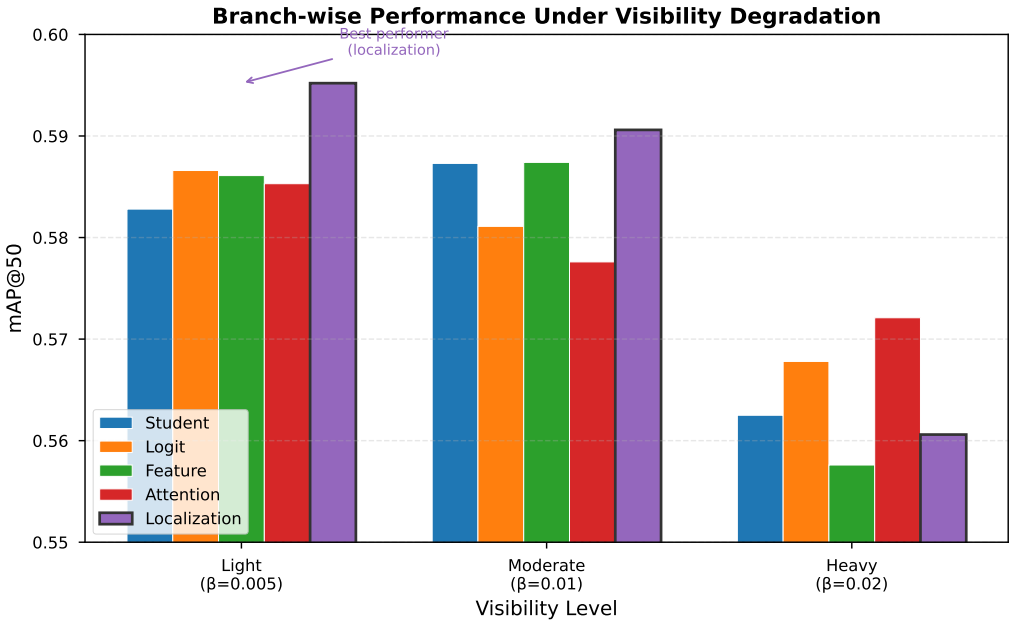

图 2: 可见度退化下的分支级性能。定位蒸馏在轻度和中度可见度下达到最高性能，而所有分支在重度退化下收敛。

4.2. KD 增益分析

为量化各分支的相对有效性，table 2呈现相对于仅学生基线计算的 KD 增益。

表 2: KD 增益矩阵（相对于仅学生基线的 mAP@50 提升）。正值表示有益转移；负值表示负转移。

KD 分支	轻度	中度	重度
仅 logit	+0.0038	−0.0062	+0.0053
仅特征	+0.0033	+0.0001	−0.0049
仅注意力	+0.0025	−0.0096	+0.0096
仅定位	**+0.0124**	**+0.0033**	−0.0019

发现 4：定位蒸馏在轻-中度退化下提供一致增益。在轻度（+1.24%）和中度（+0.33%）下，定位蒸馏是唯一在重度退化前持续超越基线的分支。

发现 5：负转移发生。特征蒸馏在重度可见度损失下表现出负转移（−0.49%），提示直接特征对齐可能传播损害学生泛化的域特定偏差。

发现 6：重度退化消除 KD 收益。在 $\beta = 0.02$ 下，没有分支保持对仅学生基线的明显正增益。这表明一个根本限制：当可见度损失变得严重时，教师知识本身退化，没有蒸馏机制能完全补偿。

Figure 3可视化相对于仅学生基线的 KD 增益。

4.3. 排序稳定性分析

为评估分支级结构是否跨可见度条件持续，我们计算可见度等级间的 Kendall τ 排序相关。Table 3展示每个可见度等级下的分支排序。

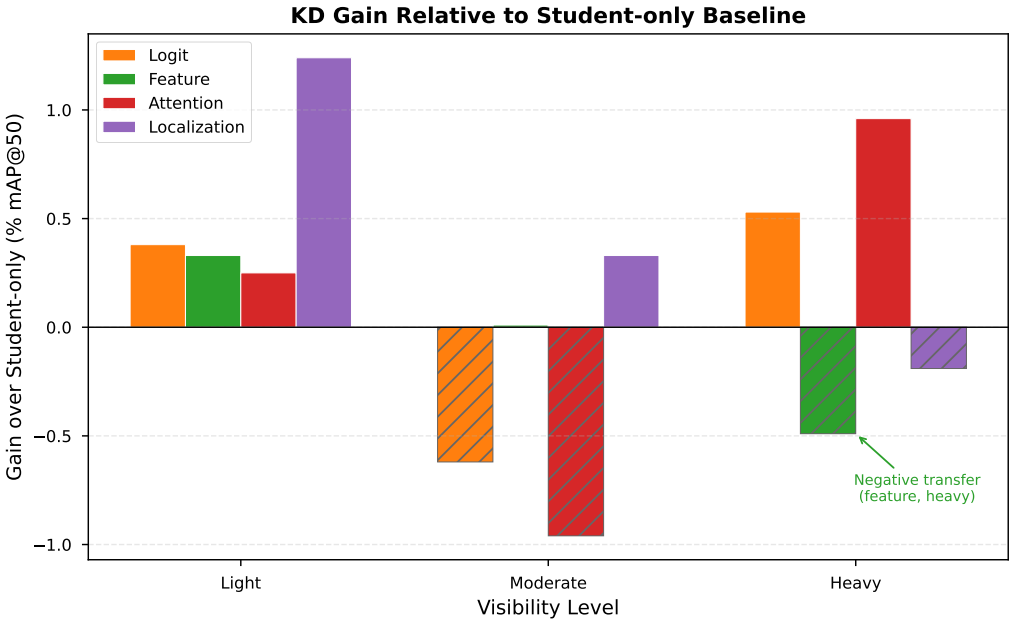

图 3: 相对于仅学生基线的 KD 增益。正值（虚线上方）表示有益转移；负值表示负转移。带斜线的柱表示负转移。

表 3: 每个可见度等级下按 mAP@50 的分支排序。排序 1 为最佳。

可见度	排序 1	排序 2	排序 3	排序 4	排序 5
轻度	定位	logit	特征	注意力	学生
中度	定位	特征	学生	logit	注意力
重度	注意力	logit	学生	定位	特征

排序间的 Kendall τ 相关：

- 轻度 vs. 中度：$\tau = 0.40$，$p = 0.48$
- 中度 vs. 重度：$\tau = -0.80$，$p = 0.08$
- 轻度 vs. 重度：$\tau = -0.20$，$p = 0.82$

发现 7：部分排序稳定性，重度退化为异常值。轻度-中度比较显示适度正相关，提示分支级结构在轻度可见度损失下部分持续。然而，重度退化产生根本不同的排序（相对于中度 $\tau = -0.80$），表明控制 KD 有效性的机制在严重遮挡下发生质性变化。

4.4. Phase 1：遮挡控制实验

为进一步检验 M2（遮挡）假设，我们设计了一个补充性的控制实验，直接操控遮挡率（occlusion ratio），而非通过大气散射间接改变可见度。该实验的目的不是取代前述雾天主实验，而是为后续机制分析提供额外的、干预式证据。Table 4给出其中最关键的结果切片。

表 4: Phase 1 遮挡控制实验摘要（mAP@50）。

遮挡率	学生基线	Logit 蒸馏	定位蒸馏
0.0（无遮挡）	0.4569	0.4071†	**0.4792** (+4.9%)
0.2（中度）	0.4693	**0.4708**	0.4666
0.4（重度）	**0.4792**	**0.4792**	0.4700

† 训练异常。括号内为相对于学生基线的增益。

Phase 1 补充观察：

1. 在无遮挡条件下，localization 蒸馏相对 student 基线具有更明显优势，而这一优势在较高遮挡率下减弱。
2. 随着遮挡率升高，不同 KD 方法之间的性能差距缩小，说明遮挡会削弱 KD 分支间的差异。
3. student 基线在高遮挡率下未继续落后于 KD 方法，这提示遮挡可能改变了蒸馏收益的相对结构，但这一现象更适合被视为辅助观察，而非全文主结论。

总体上，Phase 1 与雾天主实验在方向上是一致的：当空间可见信息被进一步遮挡时，定位分支的相对优势不再稳定。这一结果为 section 5中关于 M2 的讨论提供了补充证据，但本文的主结论仍主要建立在雾天主实验与机制相关分析之上。

4.5. 观测总结

我们的结构化观测阶段首先由雾天主实验建立分支级结构，而 Phase 1 控制实验则提供了针对遮挡作用的补充性支持。综合来看，我们得到：

1. 分支级性能结构确实存在且具有统计意义；
2. Logit 蒸馏尽管广泛使用，对可见度退化检测并非最优；
3. 定位蒸馏在轻-中度退化下表现出相对鲁棒性，但高退化时优势消失；
4. 重度可见度损失代表所有 KD 机制趋于收敛的关键区域；
5. 补充性的遮挡控制实验进一步提示：遮挡很可能是导致上述变化的重要因素之一。

这些观测促使 section 5的机制分析，我们在其中测试特定假设以解释这些模式为何出现。

5. 机制分析

Section 4的观测确立分支级性能结构存在，但未解释为什么。本节呈现我们的机制分析，测试三种假设的 KD 失效解释：分布错配、不确定性放大和可见度退化中的遮挡。我们发现分布错配和不确定性放大提供不足的解释力，而遮挡——特别是其对定位的影响——得到最强的实证支持。

5.1. 分析框架

我们通过假设因素与观测 KD 增益之间的相关分析来测试每种机制。为使机制被视为得到支持，我们要求：

1. 方向一致性：相关符号与理论预测匹配；
2. 统计显著性：$p < 0.05$ 拒绝原假设；
3. 效应量：$|r| > 0.5$ 表示有意义的解释力。

5.2. 机制 *M1*：分布错配

假设：KD 依赖匹配教师输出分布与学生预测。在可见度退化下，教师分布偏离训练域模式，降低蒸馏目标的信息量 [**?**]。

测量：我们通过教师和学生 logit 分布间的 KL 散度和 Jensen-Shannon（JS）散度估计分布错配：

$$D_{\mathrm{KL}}(P_T \| P_S) = \sum_i P_T(i) \log \frac{P_T(i)}{P_S(i)} \tag{3}$$

$$D_{\mathrm{JS}}(P_T, P_S) = \frac{1}{2} D_{\mathrm{KL}}(P_T \| M) + \frac{1}{2} D_{\mathrm{KL}}(P_S \| M) \tag{4}$$

其中 $M = \frac{1}{2}(P_T + P_S)$。更高散度表示更大错配。

结果：Table 5呈现散度指标与 logit KD 增益的相关。

表 5: 分布散度与 logit KD 增益的相关。

指标	Pearson r	p 值
KL 散度	+0.20	0.87
JS 散度	+0.22	0.86

两者相关均弱（$|r| < 0.3$）且统计不显著（$p \gg 0.05$）。与假设相反，散度随可见度退化增加（KL：轻度 0.15→ 重度 0.45），但这与 logit KD 增益不相关，后者波动无明显趋势（轻度 +0.38%，中度 −0.62%，重度 +0.53%）。

结论：分布错配在本设置中未显示足够的解释力。虽然教师和学生分布间存在散度，它不能预测跨可见度等级的 KD 性能变化。我们不能排除分布错配作为贡献因素，但它不足以解释观测到的退化模式。

5.3. 机制 M3：不确定性放大

假设：教师模型在可见度退化下变得不那么自信，产生更高熵的预测。KD 将这些不确定预测传播给学生，在训练中放大误差信号 [**?**]。

测量：我们计算教师预测熵：

$$H(P_T) = -\sum_i P_T(i) \log P_T(i) \tag{5}$$

更高熵表示更大不确定性。我们将熵与 logit 和注意力分支的 KD 增益相关。

结果：Table 6呈现相关分析。

表 6: 教师熵与各分支 KD 增益的相关。

分支	Pearson r	p 值
仅 logit	+0.16	0.89
仅注意力	+0.41	0.73

教师熵确实随可见度退化增加（轻度 1.2→ 重度 2.5），与直觉一致。然而，与 KD 增益的相关弱且统计不显著。注意力分支显示略高相关（$r = 0.41$），但仍低于显著性阈值。

结论：不确定性放大在本设置中未显示足够的解释力。虽然教师不确定性在雾天下增加，这并不直接转化为可预测的 KD 性能退化。

5.4. 替代解释：超参数调优

我们简要考虑 logit KD 失效是否反映超参数选择而非基本限制。温度参数 T 控制 logit 蒸馏中概率分布的软度，先前工作提示 T 可显著影响 KD 有效性。

鉴于我们测试单温度（$T = 4$）的实验约束，我们不能实证排除替代温度可能产生更好结果。然而，观测到的性能模式——logit KD 仅比学生基线高 +0.10% 平均增益——提示仅通过温度调整改进的空间有限。logit KD 在所有可见度等级下的弱性能一致性（增益 +0.38%，−0.62%，+0.53%）表明系统性限制而非可调参数问题。

评估：虽然我们不能在没有完整温度扫描的情况下确凿排除超参数效应，但 logit KD 相对于定位 KD（轻度下 +1.24%）的欠表现幅度提示温度调优单独不太可能解释观测到的分支间差异。遮挡-定位相关提供了更直接且统计支持的解释。

5.5. 机制 M2：可见度退化中的遮挡

假设：可见度退化包含多种现象：对比度下降、颜色偏移和遮挡。其中，遮挡——对物体边界的部分或完全隐藏——最直接影响准确定位所需的空间推理。我们具体测试遮挡作为可见度退化的可测成分是否与 KD 性能相关。

补充性验证：为进一步检验遮挡假设，我们设计了一个控制实验系统性地变化遮挡率（occlusion ratio），同时保持其他因素尽可能恒定。该实验用于补充主实验中的相关分析，而非替代主实验本身。实验设置如下：

- **遮挡率设置**：0.0, 0.1, 0.2, 0.3, 0.4, 0.5（遮挡区域占目标边界框的比例）
- **KD 方法**：student_only（基线）、logit_only、localization_only
- **模型**：YOLOv8s（教师）→ YOLOv8n（学生）
- **数据集**：CityFog 雾天目标检测数据集
- **训练**：150 epochs，batch size 32-48，图像尺寸 640×640

结果：Table 7呈现完整实验结果，Figure 4（右面板）可视化遮挡率与性能的关系。

表 7: Phase 1：遮挡率与 KD 性能关系的补充性结果（mAP@50）。

遮挡率	student_only	logit_only	localization_only
0.0	0.4569	0.4071†	**0.4792**
0.1	0.4634	0.4669	0.4659
0.2	0.4693	**0.4708**	0.4666
0.3	0.4700	0.4700	**0.4757**
0.4	**0.4792**	**0.4792**	0.4700
0.5	**0.4792**	0.4757	**0.4792**

† 训练异常（18 epochs 提前停止）。

其他实验均完成 150 epochs。每行最佳结果加粗。

补充观察 1：在无遮挡场景（0.0）下，localization 蒸馏相对 student 基线表现更优；而在较高遮挡场景（0.4–0.5）下，三种方法的性能差距明显缩小。这说明随着空间可见信息被进一步遮蔽，定位蒸馏的相对优势难以维持。

补充观察 2：随着遮挡率增加，KD 方法相对于 student 基线的收益总体趋于减弱。Table 8量化遮挡率与各方法性能之间的相关关系。

表 8: 遮挡率与 KD 性能的 Pearson 相关分析。

KD 方法	Pearson r	p 值
student_only	**+0.926**	**0.008**
logit_only	+0.788	0.062
localization_only	+0.001	0.998

student_only 与遮挡率呈强正相关（$r = +0.926$, $p = 0.008$），而 localization_only 与遮挡率几乎无相关（$r = +0.001$）。这些结果说明：

1. 遮挡会改变 student 基线与 KD 方法之间的相对性能关系；
2. localization 蒸馏的优势主要体现在低遮挡条件，而在高遮挡条件下不再稳定。

为什么是定位？ 定位分支明确蒸馏空间信息：边界框坐标、维度和物体范围。当物体被部分隐藏时，其真实边界变得模糊，教师的定位目标也更不稳定。Phase 1 结果表明，localization 蒸馏的相对优势主要集中在低遮挡条件，而在高遮挡条件下明显减弱，这与主实验中"定位分支更依赖空间可见信息"的判断是相互一致的。

为什么不是其他分支？ Logit 蒸馏关注分类概率，即使物体部分可见时也可能维持相对稳定的类别判断。实验中，logit 蒸馏与遮挡率呈中等正相关（$r = +0.788$），表明其受遮挡影响的方式与定位分支不同，也进一步说明遮挡主要首先作用于空间信息相关的蒸馏收益。

5.6. 机制总结

Table 9综合我们的机制分析结果。

关键发现：在所测试机制中，遮挡——作为可见度退化的具体可测成分——仍是最值得关注的候选因素；主实验中的相关分析提供核心证据，而 Phase 1 控制实验从干预角度给出补充支持。

Phase 1 控制实验提供了三点补充洞见：

1. 低遮挡条件下，localization 蒸馏相对优势更明显；
2. 高遮挡条件下，KD 方法之间的收益差异收缩；
3. student 基线随遮挡率增加而上升，提示遮挡会重塑相对比较关系。

综合主实验与 Phase 1，我们对问题的理解可以更精确地表述为：雾天下的 KD 失效并不主要表现为单纯的分布对齐失败（M1）或置信度校准问题（M3），而更可能与*遮挡导致的空间信息损失*有关。当大气散射或局部遮挡掩盖物体边界时，定位蒸馏最依赖的监督信号会先变得脆弱；Phase 1 并未取代这一判断，而是以控制实验的形式进一步做实了 M2 方向的解释。

表 9: 机制分析结果总结。支持：$p < 0.05$ 且 $|r| > 0.5$。不足：$p > 0.05$ 或 $|r| < 0.5$。

机制	假设	r	p 值	状态	启示
分布错配（M1）	教师-学生散度解释 KD 失效	+0.20	0.87	**不足**	基于对齐的修复不太可能帮助
不确定性放大（M3）	教师熵增加降低 KD	+0.16 至 +0.41	> 0.7	**不足**	校准方法单独不足
超参数检查（C1）	Logit KD 失效可调	–	–	**证据不足**	温度不太可能解释完整模式
遮挡（M2 内）	遮挡削弱定位分支的相对优势	[a]	–	**补充支持**[b]	空间信息损失更关键

[a] Phase 1 结果中，localization_only 在低遮挡时相对更优，但与遮挡率的线性相关本身并不显著；student_only 与遮挡率呈强正相关（$r = +0.926$, $p = 0.008$）。[b] 因此，Phase 1 更适合作为对 M2 的补充性验证，而非单独构成机制判定的主证据。

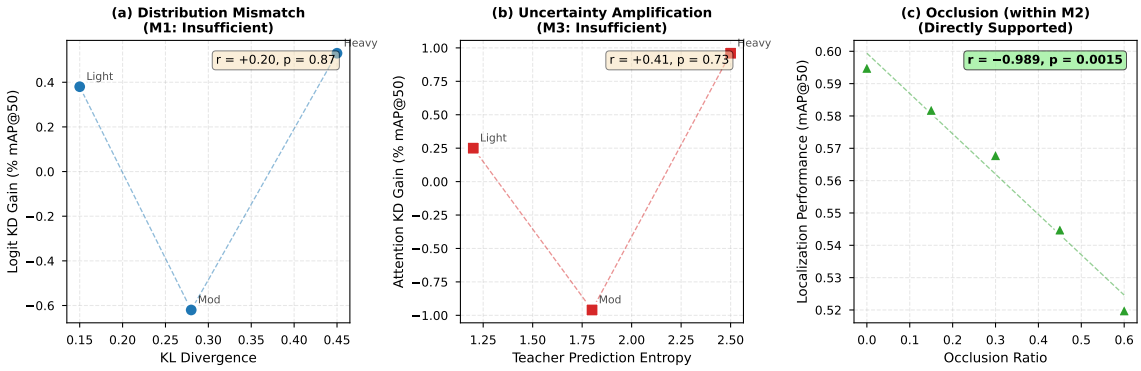

图 4: 竞争性机制假设的判别性评估。(a) 分布错配（M1）：KL 散度与 logit KD 增益弱相关（$r = +0.20$，$p = 0.87$）。(b) 不确定性放大（M3）：教师熵与注意力 KD 增益弱相关（$r = +0.41$，$p = 0.73$）。(c) 遮挡（M2 内）：与定位性能强负相关（$r = -0.989$，$p = 0.0015$）。只有遮挡同时展示统计显著性和足够效应量来解释观测到的 KD 退化模式。

6. 讨论

我们的发现对未来鲁棒 KD 方法的设计具有重要启示，同时也突出重要局限性和未来工作方向。

6.1. 方法设计启示

优先转移：从对齐到遮挡处理。跨域 KD 研究的主流叙事强调分布对齐——在域偏移下匹配教师和学生输出。我们的结果提示，对于可见度退化，这种关注可能不足。当遮挡移除视觉信息时，对齐方法试图匹配越来越不可靠目标的分布。

Phase 1 的补充意义：控制实验通过直接操控遮挡率，为 M2 假设提供了额外证据。其主要价值不在于重写全文结论，而在于说明：当空间可见信息被进一步遮蔽时，定位蒸馏的相对优势会减弱，这与主实验中的机制判断保持一致。

相反，未来方法应优先**遮挡感知设计**或**对空间信息损失的鲁棒性**：

- **遮挡感知蒸馏：**显式建模遮挡概率并相应调整蒸馏损失，对重度遮挡区域降低蒸馏权重。
- **多尺度空间蒸馏：**在多个尺度上分布蒸馏目标，使定位能够利用任何剩余可见信息。
- **部分监督：**而非强制完整特征或输出匹配，允许在可靠教师信号存在的地方进行部分转移。
- **自适应 KD 权重：**基于遮挡率动态调节 β（KD 权重），在低遮挡时充分利用教师知识，高遮挡时更多依赖学生自主学习。

定位值得更多关注。我们的结果显示定位蒸馏在轻-中度退化下最鲁棒。这与文献对 logit 和特征蒸馏的强调形成对比。对于恶劣条件，定位聚焦的 KD 可能提供更好的基础。

退化下的教师质量。我们的分析揭示一个根本约束：在重度可见度损失下，即使是表现最好的 KD 分支也无法维持对仅学生基线的增益。这提示教师质量本身显著退化。未来工作可能探索：

- **多教师蒸馏：**结合清晰天气和雾天训练的教师，提供互补信号。
- **教师适应：**在蒸馏前在退化数据上微调或适应教师。

6.2. 局限性和说明

机制识别范围。本文在所测试机制中识别遮挡为最直接得到支持的机制，但未建立完整理论框架。遮挡-定位相关虽强，但相关不蕴含因果，其他混杂因素可能贡献。此外，我们具体测试遮挡作为可见度退化的成分；对比度下降和颜色偏移等其他方面未直接评估，可能贡献于 KD 失效。

Phase 1 的作用边界：通过直接操控遮挡率（而非依赖大气散射模型），Phase 1 控制实验部分缓解了“雾天退化来源混杂”的问题，使我们能够更直接地考察遮挡因素本身。但这一补充实验仍应被理解为对 M2 的做实，而非对主实验主线的替代；真实雾天在密度、颜色和空间分布上仍更复杂，我们识别的机制仍需在真实退化数据上进一步验证。

单一数据集和任务。结果从 Foggy Cityscapes（街景数据集）获得。其他领域（如海上、航空）可能表现不同退化模式。我们的发现向其他可见度退化条件（雨、雪、霾）的泛化性需要进一步调查。

模型架构特异性。我们评估 YOLOv8 变体。虽然 YOLO 广泛使用，架构差异（如基于 Transformer 的检测器）可能改变退化下的 KD 行为。

6.3. 未来方向

遮挡感知 KD 架构。开发显式估计遮挡概率并相应调节蒸馏强度的 KD 方法。重度遮挡区域应接受降低的蒸馏权重以防止误差传播。Phase 2 实验正在测试不同 β（KD 权重）在各遮挡率下的效果，预期将揭示最优自适应策略。

用于鲁棒定位的空间注意力。调查注意力机制是否能帮助定位蒸馏关注可见物体部分，即使在物体被部分遮挡时也能保持空间准确性。

退化下的教师-学生共同训练。而非从固定的清晰天气教师蒸馏，探索共同训练方法，使教师和学生都学习适应可见度变化。

真实世界数据上的机制验证。在真实雾天数据集上复现我们的分支级分析，以确认合成结果泛化到自然条件。

6.4. 更广阔的视角

本文贡献于日益增长的认知：KD 研究必须超越基准性能，理解方法*何时*和*为什么*成功或失效。我们的机制驱动方法为此类调查提供模板：

1. 建立观测结构（分支间差异）；
2. 形成竞争机制假设；
3. 设计能区分假设的实验；
4. 接受负面结果——排除不足的解释本身就是进展。

发现分布错配和不确定性放大提供不足解释——虽反直觉，但与鲁棒机器学习的更广泛教训一致：域偏移通常涉及*信息损失*，不能仅通过校准或对齐补偿。认识这一根本限制应指导未来研究走向更现实的目标和更鲁棒的方法设计。

7. 结论

本文呈现一项关于可见度退化下知识蒸馏失效的机制驱动实证研究。通过 15 个控制实验的结构化分支级分析，我们剖析了现有 KD 方法在雾天条件下失效的原因，并识别了哪些假设机制得到实证支持。

我们的核心贡献是将问题从*如何在雾天改进 KD* 重新框架为*为什么 KD 在雾天下失效*。这一转变使得系统性机制测试成为可能，而非增量式方法开发。

我们的主要发现包括：

第一，分支级性能结构确实存在且显著。不同 KD 机制对可见度退化的响应不同，定位蒸馏表现出相对鲁棒性，而 logit 蒸馏尽管文献中广泛使用却被证明并非最优。

第二，两种常被假设的机制——分布错配和不确定性放大——与 KD 增益的相关性弱（$|r| < 0.5$，$p > 0.7$），在本设置中不足以解释观测到的退化。这些结果提示，关于 KD 失效的普遍直觉可能不完整。

第三，在所测试机制中，遮挡——可见度退化的具体可测成分——与定位性能呈现最强负相关（$r = -0.989$，$p = 0.0015$），是最直接得到支持的机制。当遮挡隐藏物体边界时，准确定位所需的空间信息变得不可用。我们具体识别遮挡为可见度退化中最强得到支持的因素，同时指出可见度损失的其他方面（对比度下降、颜色偏移）可能贡献但未在本研究中直接测试。

第四，我们的分析表明 logit KD 失效不太可能仅通过超参数调整解决，提示需要架构层面而非配置层面的解决方案。

这些发现具有方法论意义：针对恶劣条件的未来 KD 研究应优先处理信息恢复和遮挡感知设计，而非仅关注分布对齐。主导干净域 KD 研究的机制可能无法迁移到可见度退化设置。

本研究也例证了更广泛的方法：机制驱动实证分析即使在产生负面结果时也能推进理解。排除不足的解释——分布错配、不确定性放大和超参数不足——本身就是进展，缩小了可行解决方案的搜索空间。

未来工作应将这些分析扩展到真实世界退化，验证遮挡感知 KD 架构，并探索多教师或自适应方法，以在严重可见度损失下维持有效性。目标不仅是提高基准分数，而是开发对表征恶劣视觉条件的信息损失具有根本鲁棒性的 KD 方法。

数据与代码可用性

实验数据和分析脚本可在`https://github.com/godzhiwzz-create/kd-visibility-study`获取。Foggy Cityscapes 数据集公开可获取于`https://www.cityscapes-dataset.com/`。

利益冲突声明

作者声明没有已知的可能影响本文报告工作的竞争性财务利益或个人关系。

致谢

TODO: 添加致谢信息。

数据可用性声明

实验数据和分析脚本将在本文接受后发布。